

Benchmark classifier: notebook/03-classifier_benchmark.py

File này dùng để so sánh các classifier có diện với feed-forward neural network trên bài toán **binary one-vs-rest** cho từng họ transcription factor (TF).

Mac định script chạy theo split 80/20 đã có sẵn trong repo, tương ứng protocol của paper:

```
train: data/mix_data/trainset/<family>.csv
test:  data/mix_data/testset/<family>.csv
```

Mỗi file <family>.csv có:

- **sequence**: protein sequence.
- **class**: nhãn binary, 1 là family đang xét, 0 là các family còn lại.

Tiền xử lý

Với mỗi family và mỗi giá trị k, script làm:

1. Đọc train/test theo `paper_split`.
2. Tính k-mer frequency từ protein sequence.
3. Fit `DictVectorizer` trên train, transform test.
4. Chọn đặc trưng bằng `ANOVA SelectKBest(f_classif)`.
5. Fit baseline model trên train và đánh giá trên test.

Riêng `fnn_pretrained` không fit trên train. Model này load weights có sẵn và chỉ predict trên test.

Mac định:

- `--k 3`
- `--max-rows 0`: dùng full data.
- `--random-state 42`
- `--repeats 1`
- `--k345-features 1000`

Seed ảnh hưởng tới sampling và các model có `random_state`.

Model và hyperparameter

Ten trong script	Model	Hyperparameter dat thu cong
knn	KNeighborsClassifier	n_neighbors=5
xgb	XGBClassifier	n_estimators=200, max_depth=6, learning_rate=0.05, subsample=0.9, colsample_bytree=0.9, eval_metric="logloss", random_state, n_jobs
random_forest	RandomForestClassifier	n_estimators=200, random_state, n_jobs
adaboost	AdaBoostClassifier	n_estimators=200, random_state
gaussian_nb	GaussianNB	default
svc_linear	SVC	kernel="linear", random_state
svc_rbf	SVC	kernel="rbf", random_state
fnn_pretrained	Keras feed-forward neural network	load tu models/Binary-Classifier/<family>/FEEDFORWARD_k{k}.ke

Nhung tham so khac dung default cua thu vien tuong ung.

FNN pretrained

fnn_pretrained khong train lai. No load model `.keras` da co san va dung `features_mask` trong `meta.json` de lay dung 1000 features tu vector k-mer.

Nguon file:

```
models/Binary-Classifier/<family>/FEEDFORWARD_k3.keras
models/Binary-Classifier/<family>/meta.json
```

Prediction threshold:

```
0.5
```

Can ghi ro day la **pretrained FNN**, khong phai FNN duoc train lai cung baseline.

Co optimize hyperparameter khong?

Khong.

Script khong dung:

- grid search
- random search
- Bayesian optimization
- cross-validation de chon hyperparameter
- tuning rieng cho tung family

Vi vay ket qua la benchmark voi **mot bo hyperparameter co dinh**, khong phai so sanh sau khi toi uu tung model.

Output

Mac dinh:

```
test/metrics/model_benchmark/binary_classifier_benchmark.csv
test/metrics/model_benchmark/binary_classifier_benchmark_summary.csv
test/metrics/model_benchmark/binary_classifier_benchmark_fnn_comparison.csv
```

Y nghia:

- `binary_classifier_benchmark.csv`: chi tiet tung `repeat + seed + data_mode + family + k + model`.
- `binary_classifier_benchmark_summary.csv`: trung binh theo `k + model`.
- `binary_classifier_benchmark_fnn_comparison.csv`: so sanh FNN pretrained voi baseline neu cung nam trong mot file ket qua.

Co the doi output:

```
--output path/to/detail.csv
--summary-output path/to/summary.csv
--comparison-output path/to/comparison.csv
```

Lưu ý khi diễn giải kết quả

- Nếu so sánh baseline với `fnn_pretrained`, đây là so sánh baseline train lại với FNN pretrained có sẵn trong repo.
- `fnn_pretrained` đã đánh giá trên cùng test split, nên có giá trị tham khảo tốt.
- Tuy nhiên, nó không hoàn toàn công bằng như train lại FNN từ đầu với cùng seed và cùng điều kiện.